

[개발계획서]

AI 기반 회전체 설비 예지보전 및 자율제어 시스템 구축

2025.10

(주)크레오티

1. 프로젝트 개요

○ 목적

- 모터 등 핵심 회전체 설비의 상태 데이터를 실시간으로 수집·분석하여 돌발 고장을 방지하고, 예측된 잔여 수명(RUL)을 바탕으로 생산 계획(MES) 및 부품 재고(SCM)를 자율적으로 제어하는 폐쇄 루프(Closed-loop) 스마트팩토리 시스템 구축.

○ 핵심 개발 방향

- 노이즈가 심한 산업 현장 데이터를 위한 **강건한 전처리 및 특성 추출(FFT, PCA) 파이프라인** 구축.
- 설비 고장 모드 분류(1D-CNN) 및 잔여 수명 예측(LSTM)을 위한 **하이브리드 AI 모델** 개발.
- 현장의 제조 암묵지를 디지털화하고, MES/SCM과 연동하여 **시스템 자율제어 (Auto-Procurement, APS Re-routing)** 실현.

2. 시스템 아키텍처 및 데이터 흐름

- 데이터의 발생부터 최종 시스템 조치까지 총 3계층(Layer)으로 아키텍처를 설계.

계층	주요 기능	적용 기술 및 컴포넌트
Edge 계층	물리적 신호 수집 및 1차 가공	IIoT 게이트웨이, 데이터 샘플링, 원도링
AI Core 계층	고장 진단 및 수명 예측 추론	FFT, 1D-CNN, LSTM, Robust Scaler
Enterprise 계층	예측 결과 기반 자율 의사결정	Kafka 브로커, MES(APS/CMMS), SCM(MRP)

3. 핵심 개발 요소 및 기술 스펙

3.1. 데이터 수집 및 신호 전처리 파이프라인

- 데이터 수집 : 진동(3축 가속도), 전류(MCC), 온도센서 데이터의 동기화 수집.
- 정규화 (Scaling) : 공장 환경의 순간적인 스파이크 노이즈 (지게차 진동 등)에 대비하여 극단적 이상치의 영향을 배제하는 Robust Scaling 적용. (Train 셋 기준으로 Scaler 훈련 후 Test 셋에 적용하여 Data Leakage 방지)
- 차원 축소 (PCA) : 수집 개의 센서 및 도출된 특징 변수들 중 상관관계가 높은 중복 정보를 압축. 스크리 플롯(Scree Plot)을 분석하여 누적 설명 분산이 90~95%를 넘는 최적의 주성분(PC) 개수만 추출, AI 연산 부하 최소화.

3.2. 상태 진단 및 고장 분류 (Diagnosis)

○ 특징 추출 (Feature Engineering)

- 시간 영역 : RMS, 파고율(Crest Factor), 첨도(Kurtosis) 등.

- 주파수 영역 : 시계열 데이터를 FFT 변환 후, 베어링 제원을 바탕으로 산출된 고유 결함 주파수(BPFO, BPFI) 대역의 진폭(에너지) 추출.
- **고장 분류 AI (1D-CNN)** : 추출된 특징 벡터 및 주파수 스펙트럼 원본을 1D-CNN 모델에 입력하여 "베어링 내륜 파손", "축 정렬 불량" 등의 구체적 고장 모드를 높은 정확도로 자동 분류.

3.3. 잔여 수명 예측 (RUL Prediction)

- 라벨링 전략 : 설비의 초기 정상 상태 구간은 최대 수명으로 평탄하게 유지하고, 열화 시작점부터 선형으로 감소하는 ****Piece-wise Linear(부분 선형)**** 방식으로 목표변수(Y) 설정.
- 예측 AI (LSTM) : 과거의 열화 트렌드를 기억하기 위해 슬라이딩 윈도우(Sliding Window) 기법으로 3차원 시계열 데이터(배치, 타임스텝, 특징)를 구성하여 LSTM 신경망에 입력. Dropout 레이어를 통해 현장 데이터 과적합 방지.

4. 시스템 연동 방안 (MES & SCM Integration)

- AI 모델의 예측 결과(고장 알람, RUL)를 미들웨어(Kafka, RabbitMQ)를 통해 전사 시스템과 비동기 방식으로 연동함.

4.1 MES 연동 (제조 실행 및 계획)

- 설비 관리 (CMMS) : 예측된 RUL이 임계치에 도달하면 모바일 푸시 알람 및 정비 작업 지시서 자동 발행.
- 생산계획 (APS) : RUL이 며칠 남지 않은 설비가 포함된 라인의 긴급/대량 주문을 건강한 라인으로 자동 스케줄링 변경(Re-routing)하여 공정 중단 방지.

4.2 SCM 연동 (부품 재고 관리)

- 고장 모드(예: 6205-ZZ 베어링 외륜 결함)가 식별되면 ERP 재고를 실시간 조회.
- 안전재고 미달 시 벤더 리드타임 계산하여 자동으로 구매 요청서(PR) 생성 및 발주 처리.

5. 단계별 추진 일정

- 1단계 (1~2월) : 센서 선정, 엣지 컴퓨팅 구축 및 정상/고장 시계열 데이터 수집.
- 2단계 (3~5개월) : 전처리(FFT, Scaler) 파이프라인 개발 및 1D-CNN 기반 진단 모델, LSTM 기반 RUL 모델링.
- 3단계 (6~7개월) : AI모델 최적화(PCA 적용, 하이퍼파라미터 튜닝) 및 이벤트 브로커 개발.
- 4단계 (8~9개월) : MES/SCM API연동, 현장실증테스트(PoC) 및 사용자 대시보드 UI오픈.

AI 기반 회전체 설비 예지보전 및 자율제어 시스템

(기능별 세부 개발 시나리오)

- 모터와 같은 회전체 설비의 고장을 사전에 예측하고 대비하는 AI 기반 예지보전 (Predictive Maintenance, PdM) 시스템의 전체 프로세스 흐름을 정리함.
- 현장에서 발생하는 원시 데이터(Raw Data)가 AI 모델을 거쳐 최종적으로 공급망 관리 (SCM) 및 재고 최적화로 이어지는 과정은 다음과 같이 7단계로 설계할 수 있음.

1. 데이터 수집 (Data Acquisition)

- 모터의 상태를 직관적으로 대변하는 물리적 지표를 실시간으로 수집하는 가장 기초적인 단계. 고주파수 데이터가 많이 발생하므로 안정적인 산업용 IoT(IIoT) 게이트웨이 환경이 필요.
- 수집 대상:
 - 진동 센서 (Vibration): 베어링 결함, 회전축 틀어짐(Misalignment), 기계적 불균형(Unbalance) 감지 (가속도 및 속도 데이터)
 - 전류/전압 센서 (Current/Voltage): 모터 고정자/회전자 결함, 과부하 감지 (주로 모터 제어반(MCC)에 설치)
 - 온도 센서 (Temperature): 과열 및 마찰로 인한 이상 감지 (표면 온도, 윤활유 온도)
- AI/분석 도구 적용
 - Edge AI (엣지 컴퓨팅): 서버로 모든 데이터를 보내기 전, 엣지 단에서 노이즈(가짜 신호)를 필터링하고 의미 있는 주기 데이터만 압축하여 전송.

2. 데이터 처리 및 전처리 (Data Processing & Feature Engineering)

- 수집된 시계열 데이터에서 AI가 학습할 수 있는 '특징(Feature)'을 추출하는 핵심 단계.
- 처리 내용:
 - 시간 영역 분석 : 파형의 실효값(RMS), 첨도(Kurtosis), 파고율(Crest Factor) 등을 계산하여 전반적인 충격량 확인.
 - 주파수 영역 분석 : 고속 푸리에 변환(FFT)을 통해 시간 데이터를 주파수 데이터로 변환, 특정 주파수 대역에서 발생하는 비정상 피크를 확인.
- [AI/분석 도구 적용]:
 - PCA (주성분 분석), Wavelet 변환. 수많은 데이터 변수 중 고장과 가장 직결되는 핵심 변수(Feature)들만 차원 축소하여 AI 모델의 연산 부하를 줄이고 정확도를 높임.

3. 이상 신호 발견 (Anomaly Detection)

- 설비가 '정상' 상태의 패턴에서 벗어났는지를 실시간으로 판단. 초기 구축 시에는 고장 데이

터가 부족하므로 주로 비지도 학습이 활용됨.

- 처리 내용: 현재 들어오는 센서 데이터의 패턴이 과거 정상 가동 시의 패턴과 얼마나 차이(Reconstruction Error)가 나는지 점수화(Anomaly Score)함.
- [AI/분석 도구 적용]:
 - Autoencoder (오토인코더): 정상 데이터만 학습하여 정상 패턴을 복원하는 딥러닝 모델. 비정상 데이터가 입력되면 복원 오차가 커지는 원리로 이상을 탐지.
 - Isolation Forest / One-Class SVM: 다변량 데이터 속에서 통계적 특이점을 빠르게 찾아내는 머신러닝 알고리즘.

4. 고장 진단 및 알림 (Fault Diagnosis & Notification)

- 단순히 "이상이 있다"를 넘어, "어떤 부품이 어떤 형태의 고장을 일으키고 있는지"를 분류하고 담당자에게 알림.
- 처리 내용: 주파수 스펙트럼의 특정 패턴을 분석해 베어링 내륜 결함, 외륜 결함, 축 정렬 불량 등을 구체적으로 식별함.
- [AI/분석 도구 적용]:
 - CNN (합성곱 신경망) / 1D-CNN: 시계열 진동 파형이나 주파수 스펙트로그램 이미지를 학습하여 고장의 종류(모드)를 정밀하게 분류(Classification).
 - Random Forest / XGBoost: 다양한 센서 조건부 규칙을 학습하여 높은 정확도로 고장 원인을 진단함.

5. 경보 처리 (Alarm Management)

- 수많은 이상 신호 중 작업자가 즉각적으로 개입해야 하는 진짜 위험과 일시적인 노이즈를 구분하여 경보 피로도(Alarm Fatigue)를 줄임.
- 처리 내용: 단순 임계치(Threshold) 초과뿐만 아니라, 이상 상태의 지속 시간, 설비의 현재 부하 상태(생산 레시피 등)를 종합적으로 고려하여 경보의 등급(Warning, Critical 등)을 동적으로 부여함.
- [AI/분석 도구 적용]: Fuzzy Logic (퍼지 논리) 또는 규칙 기반 전문가 시스템(Rule-based System)을 AI 탐지 결과와 결합하여 오경보(False Alarm)를 최소화함.

6. 잔여 수명 예측 (RUL, Remaining Useful Life)

- 현재 발견된 미세한 이상이 설비의 완전한 정지(Breakdown)로 이어지기까지 시간이 얼마나 남았는지(예: "앞으로 150시간 후 베어링 파손 예상")를 예측.
- 처리 내용: 설비의 열화 트렌드를 시계열로 분석하여 유지보수 최적 시기를 도출.

○ [AI/분석 도구 적용]:

- LSTM (Long Short-Term Memory) / GRU: 과거부터 현재까지의 시계열 열화(Degradation) 패턴을 기억하고 미래의 궤적을 예측하는 딥러닝 모델.
- Transformer 기반 시계열 예측: 최근 각광받는 알고리즘으로 장기적인 센서 데이터의 맥락을 파악해 보다 정확한 수명을 예측합니다.


7. SCM 연동 및 부품 재고 관리 (SCM Integration & Inventory Optimization)

- AI가 예측한 잔여 수명(RUL) 데이터를 기반으로 현장의 제조실행시스템(MES) 및 공급망 관리(SCM) 시스템과 연동하여 자율적인 조치를 취함.
- 처리 내용: 모터가 완전히 정지하기 전에 교체에 필요한 예비품(베어링, 윤활유 등)의 재고를 확인하고, 부족할 경우 자동으로 발주를 생성합니다. 또한 생산 계획(APS)을 고려하여 공장 가동 중단 피해가 가장 적은 주말이나 휴게 시간에 정비 일정을 자동 배정.
- [AI/분석 도구 적용]:
 - 강화학습(Reinforcement Learning) 및 OR(Operations Research) 알고리즘: 부품 리드타임(도입 소요 시간), 창고 재고 비용, 기회비용을 계산하여 '최적의 부품 발주 시점 및 정비 스케줄링'을 도출.

구분	주요 목적	적용 적용되는 주요 AI / 데이터 분석 도구
1. 수집	물리적 신호 확보	Edge AI (노이즈 필터링, 데이터 압축)
2. 전처리	AI가 인지할 특징 추출	FFT (고속 푸리에 변환), PCA, Wavelet
3. 탐지	비정상 상태(Anomaly) 확인	Autoencoder, Isolation Forest (비지도 학습)
4. 진단	고장의 원인과 종류 분류	1D-CNN, XGBoost, Random Forest (분류 모델)
5. 경보	동적 알람 발생 및 판단	Rule-based System, 머신러닝 앙상블
6. 예측	여 수명(RUL) 시계열 추론	LSTM, GRU, Transformer (시계열 딥러닝)
7. SCM	예비품 발주 및 정비 스케줄링	강화 학습, 최적화(OR) 알고리즘, 수요예측 모델

[진동 데이터를 AI가 분석하기 좋게 주파수 대역으로 변환(FFT)하고 주요 특징을 추출하는 방법]

- 진동 센서에서 수집되는 원시 데이터(Raw Data)는 시간의 흐름에 따른 진폭을 나타내는 시간 영역(Time Domain) 데이터임. 이 상태에서는 노이즈가 너무 많고 여러 부품의 진동이 섞여 있어, AI가 "어디가 고장 났는지" 패턴을 찾아내기 매우 어려움.
- 이를 해결하기 위해 복잡한 진동 파형을 각각의 고유한 주파수 성분으로 분해하는 고속 푸리에 변환(FFT, Fast Fourier Transform)을 수행하여 주파수 영역(Frequency Domain)으로 변환해야 함.




시간 영역 파형의 주파수 분해.

(*출처: petrroudney / Getty Images)

1. 전처리 및 FFT 변환 과정

- 무작정 FFT를 돌리기 전에 데이터의 품질을 높이는 전처리 과정이 필수적임
 - **1단계: 샘플링(Sampling) 및 노이즈 필터링** : 나이퀴스트(Nyquist) 정리에 따라, 분석하고자 하는 최대 주파수의 최소 2배 이상의 샘플링 속도(Sampling Rate)로 데이터를 수집. 이후 저주파 통과 필터(Low-pass Filter)를 적용해 분석에 불필요한 고주파 기계 노이즈를 제거함.
 - **2단계: 윈도우(Windowing)** : 수집된 시계열 데이터를 일정한 크기(Window Size, 예: 1024, 2048 샘플)로 잘라서 분석함. 이때 데이터를 자른 양 끝단이 불연속적이 되어 가짜 주파수가 생성되는 현상(Spectral Leakage)을 막기 위해 Hanning 또는 Hamming 윈도우 함수를 곱해줌.
 - **3단계: FFT 수행** : 윈도우가 끝난 데이터 배열에 FFT 알고리즘을 적용함. 그 결과, X축은 주파수(Hz), Y축은 진폭(Amplitude)을 나타내는 스펙트럼 데이터가 생성됨.



FFT 변환 후의 주파수 스펙트럼

(출처: koksikoks / Getty Images)

2. 주요 특징(Feature) 추출 방안

- FFT 결과로 나온 수천 개의 주파수 데이터를 AI 모델(특히 머신러닝)에 전부 집어넣으면 차원의 저주(Curse of Dimensionality)에 빠져 학습 효율이 떨어짐. 따라서 고장을 잘 대변하는 핵심 통계량 및 주파수 특징(Feature)만 추출하여 데이터를 압축해야 함. 현업에서 예지보전 AI를 구성할 때 주로 추출하는 특징들은 다음과 같음.

A. 주파수 영역 특징 (Frequency Domain Features) : FFT 변환된 데이터에서 계산함.

- 고유 주파수 피크 (Peak Frequencies): 모터의 회전수(1X RPM) 및 그 배수(2X, 3X RPM) 주파수에서의 진폭 크기. (축 정렬 불량이나 불균형 감지에 핵심)
- 대역별 에너지 (Band Energy): 전체 주파수를 여러 구간(예: 저주파, 중주파, 고주파 대역)으로 나누고, 각 구간 내 진폭들의 제곱합(에너지)을 구함.
- 스펙트럼 중심 (Spectral Centroid): 주파수 스펙트럼의 '무게 중심'이 어느 Hz에 위치하는지 나타냄. 고장이 발생해 고주파 노이즈가 심해지면 중심이 우측으로 이동함.

B. 설비 특화 고장 주파수 (Fault Frequencies)

- 모터나 베어링의 제원(볼의 개수, 피치 직경 등)을 알고 있다면, 고장 시 튀어오르는 특정 주파수를 미리 수학적으로 계산해 두고 해당 지점의 진폭만 특징으로 추출함.
 - BPFO (외륜 결함 주파수) / BPFI (내륜 결함 주파수)
 - BSF (볼 결함 주파수) / FTF (케이지 결함 주파수)

C. 시간 영역 특징 (Time Domain Features) : FFT를 하기 전, 원본 시계열 데이터(Window) 단위에서도 중요한 통계 특징을 함께 추출하여 주파수 특징과 결합하면 AI 성능이 크게 올라감.

- RMS (실효값): 진동 에너지의 전반적인 크기. 기계가 전반적으로 얼마나 심하게 떨고 있는지 보여줌.
- Crest Factor (파고율): 최대 피크값을 RMS로 나눈 값. 베어링이 깨져서 발생하는 '순간적인 충격'을 감지하는 데 탁월함.
- Kurtosis (첨도): 신호의 뾰족한 정도. 정상 상태에서는 3에 가깝지만, 고장 초기 단계에서 충격 신호가 발생하면 이 값이 급격히 상승함.

3. AI 입력 데이터 구성 (Data Vectorization) : 추출된 특징들은 하나의 1차원 배열(Vector)로 묶여 AI 모델의 입력값으로 사용됨. 예시 (1개의 센서 데이터 Window에서 추출된 10개의 Feature Vector) : [RMS, 첨도, 파고율, 1X 주파수 진폭, 2X 주파수 진폭, BPFO 진폭, BPFI 진폭, 저주파대역 에너지, 고주파대역 에너지, 스펙트럼 중심]

- 이렇게 정제된 Feature Vector 데이터셋을 구축하면, Random Forest나 XGBoost 같은 머신러닝 분류 모델을 통해 빠르고 가볍게 고장 원인을 진단할 수 있습니다. 만약 추출 과정 없이 1D-CNN을 사용한다면, FFT 스펙트럼 원본 배열을 이미지화(Spectrogram)하여 그대로 딥러닝 모델에 입력하기도 함.

[추출된 수많은 Feature들을 PCA(주성분 분석)를 이용해 차원 축소하여 AI에 최적화하는 과정]

- 수 많은 센서 데이터와 통계적 특징(Feature)들 속에서 핵심 정보만 압축하여 AI 모델을 최적화하는 PCA(주성분 분석) 과정에 대해 상세히 설명.
- PCA를 거친 데이터는 중복된 정보와 불필요한 노이즈가 제거된 '농축된 핵심 정보' 상태가 됨. 이 데이터를 앞서 설계한 LSTM 모델에 입력하면, 연산 속도는 훨씬 빨라지면서도 잔여 수명 예측(RUL)의 정확도와 안정성을 크게 높일 수 있음.
- 수많은 Feature를 AI에 최적화하는 PCA(주성분 분석) 차원 축소 과정
- 설비 예지보전 모델을 개발할 때 진동(X, Y, Z축), 온도, 전류 센서 데이터에서 시간 영역 특징(RMS, 첨도 등)과 주파수 영역 특징(FFT 피크 등)을 모두 추출하면, 하나의 시점(Window)에 대해 수십~수백 개의 변수(Feature)가 생성됨. 이렇게 차원(변수의 수)이 너무 많아지면 모델의 학습 속도가 느려지고 과적합(Overfitting)이 발생하기 쉬운 '차원의 저주(Curse of Dimensionality)' 현상이 나타납니다. 이를 해결하기 위해 중복된 정보를 합쳐 핵심 변수로 압축하는 PCA 과정이 필수적임.

○ PCA(주성분 분석) 5단계 프로세스

1. 데이터 표준화 (Standardization)

- PCA는 '분산(데이터가 퍼진 정도)'을 극대화하는 축을 찾는 알고리즘임. 온도 데이터(예: 40~150°C)와 진동 가속도 데이터(예: 0~0.5g)를 그대로 사용하면, 값의 스케일이 큰 온도 데이터 쪽으로 중요도가 왜곡됨.
- 작업 내용: 모든 변수(Feature)를 대상으로 평균을 0, 표준편차를 1로 맞추는 Z-score Scaling(표준화)을 먼저 수행하여 모든 변수가 동등한 영향력을 갖도록 만듦.

2. 공분산 행렬 (Covariance Matrix) 도출

- 수백 개의 변수들이 서로 어떤 관계를 맺고 같이 움직이는지 수학적으로 계산함.
- 작업 내용: '모터 베어링 온도가 올라갈 때 특정 고주파 대역의 진동 에너지도 함께 증가한다'와 같이, 변수들 간의 상관관계를 나타내는 정사각 행렬(공분산 행렬)을 생성. 이렇게 함께 움직이는 변수들은 '중복된 정보'를 담고 있다는 뜻임.

3. 고유값(Eigenvalue)과 고유벡터(Eigenvector) 계산

- 공분산 행렬을 분해하여 데이터가 가장 넓게 퍼져 있는(정보량이 가장 많은) 새로운 축(주

성분)들을 찾아냄.

- 고유벡터 (방향): 기존 변수들의 선형 결합으로 만들어진 완전히 새로운 독립적인 '축 (Principal Component, PC)'입니다. PC1, PC2, PC3 등으로 명명되며, 각 축은 직교(수직)하여 서로 중복되는 정보가 전혀 없음.
- 고유값 (크기): 각 PC 축이 원본 데이터의 전체 분산(정보량) 중 얼마만큼을 설명하고 있는지를 나타내는 수치입니다. 고유값이 클수록 더 중요한 축임.

4. 주성분(PC) 개수 선택 (Scree Plot 활용)

- 수백 개의 PC 축 중에서 AI 모델에 입력할 '알짜배기 축'을 몇 개까지 선택할지 결정함.
- 작업 내용: 고유값이 큰 순서대로 정렬한 뒤, 각 PC가 설명하는 분산의 비율을 누적하여 그래프(Scree Plot)로 그림
- 실무 적용: 일반적으로 누적 설명 분산 비율(Cumulative Explained Variance Ratio)이 90% ~ 95%에 도달하는 지점에서 PC 개수를 자름. 예를 들어, 100개의 원본 Feature가 있었지만 상위 15개의 PC만으로도 전체 정보의 95%를 표현할 수 있다면, 차원을 100개에서 15개로 과감히 축소하는 것임.

5. 데이터 변환 및 투영 (Projection)


- 선택된 N개의 새로운 주성분 축(PC1 ~ PC_N)에 기존의 데이터를 투영시킴.
- 작업 내용: 100개의 변수를 가졌던 원본 데이터 행렬이 15개의 변수를 가진 새로운 행렬로 변환됨. 이 변환된 데이터가 최종적으로 1D-CNN이나 LSTM 같은 AI 모델의 입력값(Input)으로 사용됨.

PCA가 예지보전 AI 모델에 주는 3가지 이점

- 다중공선성(Multicollinearity) 완화: 서로 밀접하게 연관된 센서 데이터(예: 진동 진폭 증가와 모터 온도 상승)가 독립적인 직교 축(PC)으로 변환되므로, AI 모델이 중복된 정보로 인해 혼란을 겪거나 가중치를 잘못 부여하는 문제를 막아줍니다.
- 과적합(Overfitting) 방지 및 속도 향상: 불필요한 노이즈 특성을 가진 하위 PC들을 버리게 되므로 데이터가 깨끗해집니다. 입력 차원이 100차원에서 15차원으로 줄어들면, 딥러닝 모델의 파라미터(가중치) 수도 기하급수적으로 줄어들어 엣지(Edge) 디바이스 환경에서도 실시간 추론이 가능해집니다.
- 고장 궤적 시각화: 가장 정보량이 많은 상위 2~3개의 축(PC1, PC2, PC3)만을 이용해 데이터를 2D 또는 3D 산점도로 그리면, 수백 차원의 설비 상태 데이터를 시각화할 수 있습니다. 모터가 정상일 때는 점들이 특정 군집에 머무르다가, 고장이 진행될수록 다른 위치로 궤적을 그리며 이동하는 모습을 관제 대시보드에 표현할 수 있습니다.

[특징을 수동으로 추출하지 않고 1D-CNN을 이용해 주파수 스펙트럼 원본에서 바로 고장을 분류하는 원리]

- 1D-CNN(1-Dimensional Convolutional Neural Network)은 이미지 분석에 널리 쓰이는 2D-CNN의 원리를 시계열이나 주파수 스펙트럼 같은 1차원 배열 데이터에 적용한 딥러닝 아키텍처임.
- 사람이 일일이 수식이나 도메인 지식(베어링 제원 등)을 이용해 특징(Feature)을 뽑아낼 필요 없이, AI가 스스로 원본 주파수 데이터(FFT 결과)에서 고장 패턴을 찾아내는 엔드투엔드(End-to-End) 방식임.



진동 주파수 데이터의 1D-CNN 입력 과정. 출처: MDPI)

[1D-CNN의 핵심 작동 원리]

- 주파수 스펙트럼은 가로축이 주파수(Hz), 세로축이 진폭(Amplitude)인 긴 1차원 배열(Vector)임. 1D-CNN은 이 배열을 따라 '필터(Filter 또는 Kernel)'라는 돋보기를 이동시키며 패턴을 스캔함.

1. 합성곱 계층 (Convolutional Layer) : 특징의 자동 추출

- **작동 방식:** 1차원 형태의 필터(예: 크기가 3이나 5인 작은 배열)가 주파수 배열의 처음부터 끝까지 지정된 보폭(Stride)으로 미끄러지듯(Sliding) 이동함.
- **역할:** 이동하는 동안 필터값과 주파수 진폭 값을 곱하고 더하는 연산(합성곱)을 수행함. 이

- 과정을 통해 1차원 데이터 안에 숨어 있는 '특정 주파수 대역의 피크(Peak) 조합'이나 '에너지 밀집 구간' 같은 특징을 필터가 스스로 인식하게 됨.
- **다중 필터**: 하나의 레이어에 수십 개의 필터를 배치합니다. 어떤 필터는 저주파의 둔탁한 진동 패턴에 반응하고, 어떤 필터는 고주파의 날카로운 마찰 패턴에 강하게 반응(활성화)함.

2. 활성화 함수 (Activation Function, ReLU)

- **역할**: 합성곱 연산을 거친 값들 중 의미 없는 음수 값들은 0으로 제거하고, 양수 값들만 통과시켜 데이터의 비선형성(Non-linearity)을 부여함. 이를 통해 모델이 단순한 비례 관계가 아닌 복잡한 고장 패턴을 학습할 수 있게 됨.

3. 풀링 계층 (Pooling Layer) : 데이터 압축 및 불변성 확보

- **작동 방식**: Max Pooling(최대 풀링) 등을 사용하여, 1차원 배열의 특정 구간(예: 2개씩 묶음)에서 가장 큰 값만 남기고 나머지는 버림.
- **역할**: 데이터의 크기를 절반으로 줄여 연산량을 감소시킴. 더 중요한 것은 '위치 불변성 (Translation Invariance)'을 부여한다는 점. 모터의 회전수(RPM)가 미세하게 변해 고장 주파수 피크 위치가 좌우로 살짝 이동하더라도, 풀링을 거치면 AI가 동일한 고장 패턴으로 유연하게 인식할 수 있게 됨

4. 완전 연결 계층 (Fully Connected Layer) : 최종 고장 분류


- 여러 번의 합성곱과 풀링을 거치면, 길고 복잡했던 주파수 스펙트럼 원본이 "이 데이터는 외륜 결함 특징 80%, 불균형 특징 10%를 가지고 있다"는 식의 고도로 추상화된 핵심 정보 배열로 압축됨
- 마지막으로 이 배열을 1차원으로 쭉 펼쳐 일반적인 인공신경망에 통과시킨 뒤, Softmax 함수를 이용해 정상, 베어링 결함, 축 정렬 불량 등의 고장 확률을 0~1 사이의 값으로 최종 출력(Classification) 함.

수동 특징 추출(Machine Learning) 대비 1D-CNN의 장점

- **도메인 지식 의존도 감소**: 베어링의 제원이나 특정 결함 주파수 공식을 몰라도, AI가 충분한 양의 정상/고장 주파수 데이터를 보고 스스로 최적의 특징을 찾아냄.
- **미세한 패턴 포착**: 사람이 설계한 통계 수치(RMS, 첨도 등)로는 놓치기 쉬운 주파수 간의 복잡한 상관관계를 수많은 필터 조합을 통해 포착해 낼 수 있음.
- **End-to-End 자동화**: 전처리 파이프라인이 단순해져 실시간 스트리밍 데이터를 처리하는 엣지(Edge) 환경에 배포하기 용이함.

[설비의 잔여 수명(RUL)을 예측하기 위해 LSTM 딥러닝 모델을 어떻게 설계하고 구성해야 하는지 알려줘]

- 설비의 잔여 수명(RUL, Remaining Useful Life)을 예측하는 것은 예지보전의 '꽃'이라고 할 수 있음. 1D-CNN이 "현재 고장이 났는가?"를 분류한다면, LSTM(Long Short-Term Memory)은 "과거부터 지금까지의 설비 상태 변화 트렌드를 기억하고, 앞으로 언제 한계치(Failure Threshold)에 도달할 것인가?"를 시계열로 예측함.



잔여 수명 예측(RUL) 열화 곡선 개념 (출처: MathWorks)

- LSTM을 활용하여 RUL 예측 모델을 설계하는 구체적인 과정을 3단계로 나누어 설명함.

1. 예측의 목표(Target Label) 정의

- AI에게 "무엇을 맞출 것인가?"(Y값)를 먼저 정해주어야 함. RUL 예측에서는 주로 Piece-wise Linear(부분 선형) 방식을 사용함.
- 왜 Piece-wise Linear인가?
 - 새 모터를 설치한 직후(초기 가동)에는 잔여 수명이 무한정 줄어드는 것이 아니라, 건강한 상태(Health Index = 100%)가 일정 기간 유지됨. 그러다 특정 시점(열화 시작점)부터 급격히 상태가 나빠지며 수명이 선형적으로 감소함.
- 라벨링 방법 : 가동 초기 데이터의 RUL 값은 최대 수명(예: 130시간)으로 일정하게 깎아둡니다(평탄한 구간). 고장이 임박한 시점부터 RUL을 0을 향해 점진적으로 줄어들게(선형 감소 구간) 라벨링하여 LSTM 모델이 초기의 무의미한 변동에 민감하게 반응하지 않도록 함.


2. 시계열 데이터 구성 (Sliding Window)

- LSTM은 '과거의 연속된 시간 흐름'을 입력받아야 함. 따라서 앞서 추출한 데이터 (RMS, 진폭 피크 등)를 3차원 텐서(Batch Size, Time Steps, Features) 형태로 묶어 주는 작업이 필수적임.
- Time Steps (Window Size): "과거 몇 번의 데이터를 보고 미래를 예측할 것인가?"를 결정. 예를 들어 Time Steps = 30이라면, 과거 30번 측정된 센서 데이터 세트를 하나의 단위로 묶어 LSTM에 입력함.
- 슬라이딩 윈도우(Sliding Window): 1칸씩(또는 n칸씩) 옆으로 이동하며 이 30개의 묶음을 계속 생성.

t1 ~ t30 데이터 ----> 예측 값 Y1

t2 ~ t31 데이터 -----> 예측 값 Y2

RUL Prediction Simulator



위젯 안내: 센서의 노이즈와 열화 속도를 조절하여, 한계점(Failure Threshold)에 도달하는 잔여 수명(RUL)이 어떻게 달라지는지 시뮬레이션해 보세요.

3. LSTM 신경망 아키텍처 설계


- LSTM의 내부는 셀 상태(Cell State)와 게이트(Forget, Input, Output)라는 구조를 통해 "오래된 정보 중 불필요한 것은 잊고, 중요한 패턴만 기억"하는 강력한 능력을 갖추고 있음. 일반적인 RUL 예측용 모델 아키텍처는 다음과 같이 구성함.
- Input Layer: 3차원 형태의 슬라이딩 윈도우 데이터(예: [30, 10] = 30타임스텝, 10개 특징)가 입력됨.
- LSTM Layer 1 & 2:
 - ☞ 첫 번째 LSTM 층에서 시계열의 복잡한 열화 패턴을 추출합니다. 노드(Hidden Units) 수는 보통 64~128개로 시작함.
 - ☞ 필요에 따라 2층으로 쌓아 더 깊은 시간적 문맥(Context)을 파악하게 합니다. 이때 첫 번째 층은 시퀀스를 그대로 반환(return_sequences=True)해야 다음 층이 받을 수 있음.
- Dropout Layer: 과적합(Overfitting)을 방지하기 위해 노드의 연결을 무작위로 20~30% 끊어버림. 훈련 데이터에만 너무 맞추어지는 것을 막아 실제 현장 데이터에서의 성능을 높임.
- Fully Connected Layer (Dense Layer):
 - ☞ LSTM이 뽑아낸 시계열 특징들을 바탕으로, 최종적으로 숫자를 예측하기 위해 일반 신경망 층을 거침.
- Output Layer:
 - ☞ 단일 뉴런(Dense(1)): 활성화 함수 없이 선형(Linear) 값을 출력하도록 설정. 이 출력값이 바로 "앞으로 남은 수명(사이클 또는 시간)"을 의미하는 연속된 실수 값이 됨.

[실무 설계 팁]

- 손실 함수(Loss Function) : 회귀(Regression) 문제이므로 MSE(평균제곱오차)나 RMSE를 사용하여 실제 RUL과 예측 RUL 간의 차이를 최소화하는 방향으로 학습시킴.
- 최근 트렌드 (Attention / Transformer) : 최근에는 긴 시계열 데이터에서 '정확히 어느 시점의 데이터가 가장 중요했는지' 가중치를 스스로 학습하는 Attention Mechanism을 LSTM에 결합하거나, 아예 Transformer 모델을 도입하여 예측 정확도를 끌어올리는 시도가 많음.

[예지보전과 MES/SCM 연동 방안]

- 예지보전 모델의 결과를 공장의 기존 MES 시스템이나 SCM(부품 재고 관리) 모듈과 어떻게 데이터적으로 연동할 수 있는지 아키텍처 방안을 알려줘.
- 단순히 고장을 예측하는 것을 넘어, 다수의 공장 라인에 구축된 기존 통합 시스템 환경에서 이 예측이 실제 조치로 이어지게 하려면 AI 예측 서버 - MES(제조실행시스템) - SCM(공급망관리) 간의 매끄러운 데이터 연동 아키텍처가 필수적임.
- 특히 생산 공정의 중단이 전체 라인에 치명적인 영향을 미치는 환경에서는, 예측된 잔여 수명(RUL) 데이터를 기반으로 생산계획(APS)을 자율적으로 재조정하고 부품을 미리 확보하는 '폐쇄 루프(Closed-loop)'를 구성해야 함.



MES 및 ERP 연동 아키텍처 (Connectivity to Enterprise). (출처: Hicron Software)

[데이터 연동 아키텍처 3단계]

- 예지보전 모델의 결과값을 공장 운영 시스템에 전달하기 위한 아키텍처는 크게 미들웨어 계층, MES 연동 계층, SCM 연동 계층으로 설계할 수 있음.

1. 미들웨어 계층 (Event Broker & API Gateway)

- AI 모델이 산출한 결과(이상 탐지 알람, RUL 수치, 고장 진단명)를 MES와 SCM이 이해할 수 있는 표준 데이터 포맷(JSON 등)으로 변환하여 전달하는 허브 역할을 함.
- 비동기 메시지 큐 (Kafka, RabbitMQ): 다수의 모터 설비에서 초당 수천 건씩 발생하는 진단 결과를 안정적으로 버퍼링하고, MES나 SCM 모듈이 각자 필요한 데이터만 구독(Subscribe)하여 가져가도록 구성함.

- REST API / Webhook: 긴급도가 높은 '위험(Critical)' 알람이 발생했을 때, 이벤트 브로커가 즉시 MES의 설비 관리 모듈로 Webhook을 쏘서 작업 지시서를 강제 생성하도록 만듦.

2. MES 연동 계층 (제조 실행 및 스케줄링)


- RUL 데이터는 MES 내의 설비 관리(CMMS) 모듈과 고급 생산 계획(APS, Advanced Planning & Scheduling) 모듈에 즉각적으로 반영되어야 함.
- **작업 지시서(Work Order) 자동 생성:** LSTM 모델이 "3번 라인 모터 베어링의 RUL이 72시간 남음"을 미들웨어로 전송하면, MES는 이를 수신하여 담당 보전 작업자에게 모바일 푸시 알람과 함께 정비 작업 지시서를 자동 발행합니다.
- **APS 기반 생산계획 자율제어:** 이것이 가장 고도화된 연동 방식. 특정 모터의 수명이 3일밖에 남지 않았다면, MES의 APS 모듈은 해당 라인에 배정되었던 긴급/대량 생산 주문을 RUL이 넉넉한 다른 정상 라인으로 스케줄링을 자동 변경(Re-routing)하여 공정 중단을 방지함.

3. SCM 연동 계층 (부품 재고 및 공급망 관리)

- 정비 작업 지시가 내려져도 창고에 교체할 베어링이나 윤활유가 없다면 무용지물임. RUL 예측 결과는 SCM의 자재 소요 계획(MRP)과 직접 연결됨.
- 안전 재고 실시간 체크: AI가 특정 규격의 베어링(예: 6205-ZZ) 결함을 진단하면, SCM 모듈은 ERP DB를 조회하여 해당 부품의 현재 재고량을 확인함.
- 자동 발주(Auto-Procurement): 창고에 부품이 없거나 안전 재고 미만일 경우, SCM은 해당 부품 공급사(Vendor)의 납기 리드타임을 계산하여 시스템상에서 자동으로 구매 요청서(PR)를 생성하고 승인권자에게 알림을 보냄

시나리오로 보는 통합 데이터 흐름

- Predictive Maintenance Integration Architecture



[연동 시나리오 요약]

[AI 서버] "모터 A의 잔여 수명(RUL)이 5일로 예측됨. 원인은 내륜 베어링 마모." (Kafka를 통해 메시지 발행)
[SCM 시스템] 해당 베어링의 창고 재고 확인 → 재고 0개 확인 → 리드타임이 2일인 협력사에 즉시 자동 발주 전송.
[MES 시스템] APS 모듈이 발주된 부품이 도착하는 3일 뒤 야간 교대 시간에 해당 설비의 유지보수 일정을 배정. 그전까지는 설비 부하를 줄이기 위해 생산 속도를 20% 낮추도록 자율 제어(Control) 지시 하달.

이러한 유기적인 아키텍처가 뒷받침되어야 단순한 기술 도입을 넘어, 제조 현장의 암묵지를 디지털화하고 자율 제어까지 가능한 진정한 스마트 팩토리를 구현할 수 있음.

[베어링 제원을 바탕으로 내륜 및 외륜의 결함 주파수(BPFO, BPFI)를 어떻게 계산하는지 공식과 예시]

○ 베어링의 결함 주파수는 모터의 회전 속도와 베어링의 기하학적 제원을 수학적으로 계산하여 도출. 진동 데이터의 FFT 스펙트럼에서 이 특정 주파수 대역에 뚜렷한 피크(Peak)가 발생한다면, 복잡한 데이터 분석 없이도 직관적으로 베어링의 어느 부위에 결함이 생겼는지 알 수 있음.

1. 계산에 필요한 베어링 제원 (변수)

공식을 적용하려면 대상 베어링의 제조사 카탈로그나 도면에서 다음의 5가지 제원 값을 확인해야 함.

f_r : 모터의 회전 주파수 (Hz) = RPM/60

N: 굴림체(볼 또는 롤러)의 개수

B_d : 볼의 직경 (Ball diameter)

P_d : 피치 직경 (Pitch diameter), 보통 내경과 외경의 평균값으로 계산

θ : 접촉각 (Contact angle), 일반적인 깊은 홈 볼 베어링의 경우 축 방향 하중이 없으면 보통 0° 이므로 $\cos\theta=1$ 을 적용함.

2. 결함 주파수 산출 공식

내륜과 외륜에 흠집이나 파손이 생겼을 때, 굴림체가 그 결함 부위를 지나가며 연속적으로 발생하는 충격의 주파수를 수식으로 나타내면 다음과 같음.

[외륜 결함 주파수 (BPFO, Ball Pass Frequency Outer race)]

일반적으로 외륜이 하우징에 고정되어 있고 내륜이 회전할 때, 외륜 궤도면에 생긴 결함 부위를 볼이 치고 지나가는 타격 주파수임.

$$BPFO = \frac{N}{2} f_r \left(1 - \frac{B_d}{P_d} \cos \theta \right)$$

참고: 공식의 괄호 안 부호가 BPFI는 +이고 BPFO는 -이므로, 동일한 설비에서 항상 내륜 결함 주파수 (BPFI)가 외륜 결함 주파수(BPFO)보다 높게 나타남.

내륜 결함 주파수 (BPFI, Ball Pass Frequency Inner race)

내륜이 축과 함께 회전하면서, 내륜 자체 궤도면에 생긴 결함 부위가 볼과 반복적으로 부딪히며 발생하는 타격 주파수임

$$BPFI = \frac{N}{2} f_r \left(1 + \frac{B_d}{P_d} \cos \theta \right)$$

3. 계산 예시 (가상의 볼 베어링 적용)

현장에서 가동 중인 모터가 1800 RPM으로 회전하고 있으며, 모터축을 지지하는 베어링의 제원이 다음과 같다고 가정.

- 회전 속도 (RPM): 1800 → $f_r = 1800/60 = 30$ Hz
- 볼 개수 (N): 9 개
- 볼 직경 (B_d): 8 mm
- 피치 직경 (P_d): 40 mm
- 접촉각 (θ): 0° ($\cos 0^\circ = 1$)

BPFO (외륜 결함) 계산

$$BPFO = \frac{9}{2} \times 30 \times \left(1 - \frac{8}{40} \times 1 \right)$$

$$BPFO = 4.5 \times 30 \times (1 - 0.2) = 135 \times 0.8 = 108 \text{ Hz}$$

$$BPFO = 4.5 \times 30 \times (1 - 0.2) = 135 \times 0.8 = 108 \text{ Hz}$$

BPFI (내륜 결함) 계산

$$BPFI = \frac{9}{2} \times 30 \times \left(1 + \frac{8}{40} \times 1 \right)$$

$$BPFI = 4.5 \times 30 \times (1 + 0.2) = 135 \times 1.2 = 162 \text{ Hz}$$

4. 데이터 분석 시 활용 방안

예지보전 시스템은 FFT 변환을 거친 주파수 스펙트럼에서 108 Hz 대역(및 그 배수 216 Hz, 324 Hz 등)에서 비정상적인 피크가 지속적으로 감지되면 외륜 파손으로 진단합니다. 반대로 162 Hz 대역에서 피크가 튀어오르면 내륜 파손으로 판단하게 됨.

머신러닝 모델(XGBoost, Random Forest 등)의 파이프라인을 구축할 때, 수천 개의 전체 주파수 데이터를 모두 학습시키는 대신 사전에 계산된 이 특정 고장 주파수(108 Hz, 162 Hz) 주변 대역의 진폭값(Amplitude)만을 Feature(특징)로 추출하여 모델에 전달하면 AI의 분류 정확도와 연산 속도를 극대화할 수 있음.

[센서마다 값이 다른 진동이나 온도 데이터를 LSTM에 넣기 전에 어떻게 정규화(Scaling)해야 하나?]

- 진동 가속도 데이터(예: 0.001 ~ 0.5g)와 온도 데이터(예: 40 ~ 150°C)처럼 단위와 측정 범위가 완전히 다른 센서 데이터를 그대로 LSTM에 넣으면, 모델이 값이 큰 온도 데이터에만 과도한 가중치를 부여하는 왜곡이 발생합니다. 또한, LSTM 내부의 활성화 함수(Sigmoid, Tanh)는 보통 0이나 1 근처에서 잘 작동하므로, 입력값의 스케일을 맞춰주는 정규화(Scaling)는 예측 정확도를 결정짓는 핵심 전처리 과정임.
- 공장 환경과 같은 노이즈가 많은 산업 데이터에 적용할 수 있는 대표적인 3가지 정규화 방법과 현장 적용 팁을 설명함.

1. Min-Max 정규화 (Normalization)

- 데이터의 최소값과 최대값을 기준으로 모든 데이터를 0과 1 사이의 값으로 압축함.

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- 특징: 데이터의 원래 분포 모양을 그대로 유지함.
- 적용 대상: 온도, RPM, 압력 등 상한과 하한이 물리적으로 명확하게 정해져 있고, 심각한 노이즈나 튀는 값이 적은 데이터에 적합함.
- 한계점: 센서의 일시적인 오작동으로 단 하나의 엄청난 이상치(Outlier)가 발생하여 최대값(X_{max})이 비정상적으로 커지면, 나머지 모든 정상 데이터가 0에 가깝게 찌그러지는 치명적인 단점이 있음.

2. 표준화 (Standardization / Z-score Scaling)

- 데이터의 평균을 0, 표준편차를 1로 맞추어 정규분포(종 모양) 형태로 변환함.

공식

$$Z = \frac{X - \mu}{\sigma}$$

- 특징: 상한/하한의 제한이 없으며, 데이터가 평균을 중심으로 어느 정도 퍼져 있는지를 나타냄.
- 적용 대상: 진동 파형 데이터처럼 원래부터 평균(보통 0 부근)을 중심으로 위아래로 대칭적인 진폭을 가지는 신호에 매우 적합함. Min-Max보다 이상치의 영향을 덜 받음.

3. Robust 정규화 (Robust Scaling)

- 평균과 표준편차 대신, 데이터의 중앙값(Median)과 사분위수 범위(IQR, 상위 25%와 75%의 차이)를 사용하여 스케일링함.
- 공식:

$$X_{robust} = \frac{X - Median}{IQR}$$

- 특징: 극단적인 이상치(Outlier)를 아예 계산 기준에서 배제해 버림.
- 적용 대상: 실제 공장 현장! 지게차가 지나갈 때 발생하는 바닥 진동, 센서의 순간적인 접촉 불량 등으로 인해 의미 없는 스파이크(가짜 피크) 노이즈가 빈번하게 발생하는 열악한 환경의 설비 데이터를 LSTM에 넣을 때 가장 안전하고 강력한 성능을 냄.

스케일링 변화 시각화

- 스케일링 방식(Min-Max, Standard, Robust)을 변경해 보며, 노이즈(이상치)가 포함된 센서 데이터가 어떻게 변환되는지 직관적으로 비교해 보기

[실무 주의사항] Data Leakage (데이터 누수) 방지

- LSTM 예지보전 모델을 훈련시킬 때 가장 많이 하는 실수가 훈련(Train) 데이터와 테스트(Test) 데이터를 한 번에 묶어서 스케일러(Scaler)를 적용하는 것임. 이렇게 하면 미래에 발생할 테스트 데이터의 정보(최대값이나 평균)가 훈련 데이터의 스케일링에 섞여 들어가는 '데이터 누수'가 발생하여, 실전 도입 시 모델 성능이 급락함.

○ 올바른 프로세스:

- ☞ 과거 데이터를 Train / Validation / Test 셋으로 나눔.
- ☞ fit_transform()을 사용하여 오직 Train 데이터의 기준(평균, IQR 등)으로만 스케일러를 학습 시킴
- ☞ 훈련된 스케일러 모델을 저장(Pickle 등)해 둬م.
- ☞ Test 데이터나 실제 공장에서 실시간으로 들어오는 새로운 센서 데이터는 transform()만 적용하여, 과거 Train 데이터의 기준을 그대로 덧붙여 스케일링한 후 LSTM에 입력함.

[온도, 진동, 전류 등 센서 변수가 너무 많을 때, PCA(주성분 분석)를 이용해 핵심 변수만 추려내어 AI 입력 차원을 줄이는 과정]

- 설비 예지보전을 구축하다 보면 진동(X, Y, Z축), 온도, 전류, 전압 등 센서의 개수만 수십 개에 달하는 경우가 많음. 여기서 FFT 특징(Feature)들까지 추가하면 입력 변수(차원)가 수백 개로 늘어남.
- 문제는 이 수백 개의 변수 중 상당수가 '서로 중복된 정보'를 담고 있다는 점임. 예를 들어 모터 베어링이 마모되면 진동(RMS)도 커지고 마찰열 때문에 온도도 같이 올라감. 두 변수는 강한 상관관계를 가지므로, 굳이 두 개를 다 넣지 않고 '두 현상을 관통하는 하나의 핵심 축(주성분)'으로 합쳐서 AI에 넣는 것이 바로 PCA(주성분 분석, Principal Component Analysis)의 목적임.
- PCA를 통해 수백 차원의 원본 데이터를 정보 손실을 최소화하면서 10~20차원으로 압축하는 과정을 단계별로 설명함.

PCA 작동 프로세스 (4단계)

1단계: 데이터 정규화 (Standardization)

- PCA는 '분산(데이터가 퍼진 정도)'을 극대화하는 방향을 찾는 알고리즘임. 따라서 온도는 40~150이고 진동은 0~0.5인 상태 그대로 돌리면, 숫자가 큰 온도 데이터 쪽으로 축이 왜곡됨.
- 조치: 앞서 다룬 표준화(Z-score Scaling)를 적용해 모든 변수의 평균을 0, 표준편차를 1로 맞춰 스케일을 통일함.

2단계: 공분산 행렬 (Covariance Matrix) 계산

- 정규화된 수많은 센서 변수들이 '서로 얼마나 함께 변하는가(상관관계)'를 수치화한 정사각 행렬을 만듦.
- 진동과 온도가 같이 오르면 양의 공분산, 하나는 오르고 하나는 떨어지면 음의 공분산을 가짐. 이를 통해 중복된 정보가 어디에 몰려 있는지 수학적으로 파악할 수 있음.

3단계: 고유벡터(Eigenvector)와 고유값(Eigenvalue) 추출

- 공분산 행렬을 수학적으로 분해하여 새로운 '축(주성분)'들을 찾아냄.
- 고유벡터 (방향): 데이터가 가장 길게 흩어져 있는 방향을 가리키는 새로운 축(Principal Component, PC)임. 첫 번째 축(PC1)이 분산을 가장 많이 설명하고, 두 번째 축(PC2)은 PC1과 수직(직교)이면서 그다음으로 데이터를 잘 설명하는 방향으로 그어짐.
- 고유값 (크기): 각 고유벡터(PC축)가 원본 데이터의 정보를 얼마나 많이(크게) 담고 있는지를


나타내는 수치임.

4단계: 주성분(PC) 개수 선택 및 차원 축소 (Projection)

- 고유값이 큰 순서대로 주성분을 나열한 뒤, "원본 정보의 몇 %를 보존할 것인가?"를 기준으로 상위 N개의 축만 선택함. 그리고 원본 데이터를 이 새로운 축들에 투영(Projection)함.

몇 개의 주성분을 남겨야 할까? (Scree Plot)

- 실무에서는 누적 설명 분산 비율(Cumulative Explained Variance Ratio)을 나타내는 '스크리 플롯(Scree Plot)'을 보고 차원의 개수를 결정함.



수많은 Feature를 AI에 최적화하는 PCA(주성분 분석) 차원 축소 과정

- 설비 예지보전 모델을 개발할 때 진동(X, Y, Z축), 온도, 전류 센서 데이터에서 시간 영역 특징(RMS, 첨도 등)과 주파수 영역 특징(FFT 피크 등)을 모두 추출하면, 하나의 시점(Window)에 대해 수십~수백 개의 변수(Feature)가 생성됨.
- 이렇게 차원(변수의 수)이 너무 많아지면 모델의 학습 속도가 느려지고 과적합(Overfitting)이 발생하기 쉬운 '차원의 저주(Curse of Dimensionality)' 현상이 나타납니다. 이를 해결하기 위해 중복된 정보를 합쳐 핵심 변수로 압축하는 PCA 과정이 필수적임.

PCA(주성분 분석) 5단계 프로세스

1. 데이터 표준화 (Standardization)

- PCA는 '분산(데이터가 퍼진 정도)'을 극대화하는 축을 찾는 알고리즘임. 온도 데이터(예:

40~150°C)와 진동 가속도 데이터(예: 0~0.5g)를 그대로 사용하면, 값의 스케일이 큰 온도 데이터 쪽으로 중요도가 왜곡됨.

- 작업 내용: 모든 변수(Feature)를 대상으로 평균을 0, 표준편차를 1로 맞추는 Z-score Scaling(표준화)을 먼저 수행하여 모든 변수가 동등한 영향력을 갖도록 만듦.

2. 공분산 행렬 (Covariance Matrix) 도출

- 수백 개의 변수들이 서로 어떤 관계를 맺고 같이 움직이는지 수학적으로 계산함.
- 작업 내용: '모터 베어링 온도가 올라갈 때 특정 고주파 대역의 진동 에너지도 함께 증가한다'와 같이, 변수들 간의 상관관계를 나타내는 정사각 행렬(공분산 행렬)을 생성함. 이렇게 함께 움직이는 변수들은 '중복된 정보'를 담고 있다는 뜻임.

3. 고유값(Eigenvalue)과 고유벡터(Eigenvector) 계산

- 공분산 행렬을 분해하여 데이터가 가장 넓게 퍼져 있는(정보량이 가장 많은) 새로운 축(주 성분)들을 찾아냄.
- 고유벡터 (방향): 기존 변수들의 선형 결합으로 만들어진 완전히 새로운 독립적인 '축 (Principal Component, PC)'입니다. PC1, PC2, PC3 등으로 명명되며, 각 축은 직교(수직)하여 서로 중복되는 정보가 전혀 없음.
- 고유값 (크기): 각 PC 축이 원본 데이터의 전체 분산(정보량) 중 얼마만큼을 설명하고 있는지를 나타내는 수치입니다. 고유값이 클수록 더 중요한 축임.

4. 주성분(PC) 개수 선택 (Scree Plot 활용)

- 수백 개의 PC 축 중에서 AI 모델에 입력할 '알짜배기 축'을 몇 개까지 선택할지 결정함.
- 작업 내용: 고유값이 큰 순서대로 정렬한 뒤, 각 PC가 설명하는 분산의 비율을 누적하여 그 래프(Scree Plot)로 그림.
- 실무 적용: 일반적으로 누적 설명 분산 비율(Cumulative Explained Variance Ratio)이 90% ~ 95%에 도달하는 지점에서 PC 개수를 자릅니다. 예를 들어, 100개의 원본 Feature가 있었지만 상위 15개의 PC만으로도 전체 정보의 95%를 표현할 수 있다면, 차원을 100개에서 15개로 과감히 축소하는 것임

5. 데이터 변환 및 투영 (Projection)

- 선택된 N개의 새로운 주성분 축(PC1 ~ PC_N)에 기존의 데이터를 투영시킴.
- 작업 내용: 100개의 변수를 가졌던 원본 데이터 행렬이 15개의 변수를 가진 새로운 행렬로 변환됨. 이 변환된 데이터가 최종적으로 1D-CNN이나 LSTM 같은 AI 모델의 입력값(Input)으로 사용됨.

PCA가 예지보전 AI 모델에 주는 3가지 이점

- 다중공선성(Multicollinearity) 완화: 서로 밀접하게 연관된 센서 데이터(예: 진동 진폭 증가와 모터 온도 상승)가 독립적인 직교 축(PC)으로 변환되므로, AI 모델이 중복된 정보로 인해 혼란을 겪거나 가중치를 잘못 부여하는 문제를 막아줌.
- 과적합(Overfitting) 방지 및 속도 향상: 불필요한 노이즈 특성을 가진 하위 PC들을 버리게 되므로 데이터가 깨끗해짐. 입력 차원이 100차원에서 15차원으로 줄어들면, 딥러닝 모델의 파라미터(가중치) 수도 기하급수적으로 줄어들어 엣지(Edge) 디바이스 환경에서도 실시간 추론이 가능해짐.
- 고장 궤적 시각화: 가장 정보량이 많은 상위 2~3개의 축(PC1, PC2, PC3)만을 이용해 데이터를 2D 또는 3D 산점도로 그리면, 수백 차원의 설비 상태 데이터를 시각화할 수 있음. 모터가 정상일 때는 점들이 특정 군집에 머무르다가, 고장이 진행될수록 다른 위치로 궤적을 그리며 이동하는 모습을 관제 대시보드에 표현할 수 있음.

LSTM 예측 모델을 위한 센서 데이터 정규화(Scaling) 가이드

- 진동 가속도(예: 0~0.5g)와 온도(예: 40~150°C)처럼 단위와 측정 범위가 전혀 다른 데이터를 그대로 LSTM에 입력하면 심각한 문제가 발생함. LSTM 내부의 활성화 함수(Tanh, Sigmoid)는 입력값이 너무 크면 기울기 소실(Vanishing Gradient) 현상을 일으켜 학습이 멈춰버리며, 값이 큰 온도 데이터에만 과도한 가중치가 부여됨.
- 성공적인 LSTM 모델 학습을 위한 정규화 기법과 실무 적용 시 주의사항을 정리함.

1. 산업용 센서 데이터에 적합한 정규화 기법 3가지

- 공장 설비 데이터는 센서 오작동이나 외부 충격으로 인한 이상치(Outlier)가 매우 빈번하게 발생함. 상황에 맞춰 다음 방법 중 하나를 선택해야 함.

□ Robust Scaling (가장 추천)

- 원리: 평균과 표준편차 대신, 데이터의 중앙값(Median)과 사분위수 범위(IQR, 25%~75% 구간)를 사용하여 스케일링합니다.
- 장점: 지게차 이동 등으로 발생한 순간적인 진동 스파이크(극단적 이상치)를 무시하고 정상적인 데이터의 분포를 안정적으로 유지합니다. 현장 예지보전 데이터에 가장 적합합니다.

□ Standardization (Z-score 표준화)

- 원리: 데이터의 평균을 0, 표준편차를 1로 맞추어 종 모양의 정규분포 형태로 변환합니다.
- 장점: 상한/하한의 제한이 없어 진동 파형처럼 평균(0)을 중심으로 진동하는 데이터에 잘 맞습니다.

□ Min-Max Scaling

- 원리: 최소값을 0, 최대값을 1로 압축합니다.
- 단점: 이상치가 하나라도 튀어버리면 (예: 온도가 순간 500도로 찍힘), 나머지 모든 정상 데이터가 0에 가깝게 찌그러져버려 LSTM이 패턴을 인식할 수 없게 됩니다.

2. LSTM 적용 시 가장 많이 하는 실수: 차원(Dimension) 문제

- Python의 scikit-learn 등에서 제공하는 스케일러 모듈은 보통 2차원 데이터 (샘플 수, 변수 수)를 처리하도록 설계되어 있음.
- 하지만 LSTM의 입력은 슬라이딩 윈도우를 거친 3차원 데이터 (샘플 수, 타임스텝, 변수 수)입니다. 이를 해결하는 올바른 순서는 다음과 같음.

[올바른 데이터 처리 순서]

- 원시 데이터(2차원) 스케일링: 슬라이딩 윈도우로 시계열을 묶기 전, 센서 열(Column) 단위로 나열된 2차원 원본 데이터 상태에서 먼저 스케일링을 수행합니다.
- 슬라이딩 윈도우 적용: 정규화가 완료된 깔끔한 데이터 위에서 윈도우(예: 30 Time Steps)를 밀어가며 3차원 텐서로 변환합니다.
- LSTM 입력: 변환된 3차원 데이터를 모델에 학습시킵니다.
- 주의: 만약 부득이하게 3차원으로 먼저 변환했다면, 스케일링을 위해 임시로 2차원으로 펼쳤다가(Flatten) 스케일링 후 다시 3차원으로 복구(Reshape)해야 합니다.

3. 치명적인 오류: 데이터 누수(Data Leakage) 방지

- 시계열 예측에서 가장 중요한 원칙은 "과거의 정보로만 미래를 예측해야 한다"는 것입니다. 전체 데이터를 한꺼번에 스케일링하면, 미래(Test) 데이터의 통계 정보(최대값, 평균 등)가 과거(Train) 데이터를 스케일링하는 데 섞여 들어가는 '데이터 누수'가 발생합니다. 이렇게 학습된 모델은 실전에 투입되면 성능이 처참하게 무너집니다.

[안전한 실무 스케일링 프로세스]

- **데이터 분할**: 전체 시계열 데이터를 시간순으로 Train(훈련), Validation(검증), Test(평가) 셋으로 먼저 나눕니다.
- **스케일러 훈련**: fit() 함수는 오직 Train 데이터에만 적용하여 평균, 분산, 중앙값 등의 '기준점'을 학습합니다.
- **데이터 변환**: 학습된 기준점을 이용하여 Train, Validation, Test 데이터 전체에 transform() 함수를 적용해 스케일링합니다.
- **스케일러 저장**: 실시간 모니터링 시 들어오는 새로운 데이터도 반드시 이 과거의 Train 기준점으로 스케일링되어야 하므로, 학습된 Scaler 객체를 파일(Pickle 등)로 저장하여 운영 서버(MES/Edge)에 배포해야 합니다.

LSTM 기반 설비 잔여 수명(RUL) 예측 모델 설계 가이드

- 잔여 수명(Remaining Useful Life, RUL) 예측은 설비가 현재 시점으로부터 완전히 고장(Failure) 나기 전까지 정상적으로 가동될 수 있는 남은 시간이나 사이클을 추정하는 회귀(Regression) 문제입니다. 시계열 데이터 처리에 탁월한 LSTM 모델을 RUL 예측에 맞게 설계하는 4단계 핵심 과정을 정리함.

1. Target Label (정답값) 정의: Piece-wise Linear RUL

- AI 모델을 학습시키려면 센서 데이터(X)에 대응하는 정답(Y, 잔여 수명)을 만들어야 함. 단순히 전체 수명을 선형으로 깎아내리는 것보다 실무에서는 부분 선형(Piece-wise Linear) 함수를 주로 사용함.
- 초기 정상 구간 (건강 상태): 새 부품을 장착한 직후에는 설비가 건강하므로 잔여 수명이 급격히 줄어들지 않음. 이 구간에서는 RUL을 최대치(예: 130 사이클)로 평탄하게(Flat) 유지시킴
- 열화 시작 구간 (선형 감소): 특정 시점(고장의 징후가 나타나는 시점)부터는 설비 상태가 나빠지며 수명이 선형적으로 깎임. 이때부터 RUL 값을 0을 향해 1씩 감소시킴
- 장점: 모델이 정상 구간의 미세한 노이즈에 과민 반응하여 수명이 깎였다고 오판하는 것을 방지합니다.

2. 데이터 구성: Sliding Window (3차원 텐서 변환)

- LSTM은 단일 시점의 데이터가 아닌 '과거 시간의 흐름'을 입력받아야 합니다. 정규화와 PCA(차원 축소)를 마친 2차원 데이터를 3차원 텐서 (Samples, Time Steps, Features) 로 변환해야 합니다.
- Time Steps (윈도우 크기): 과거 몇 개의 시점을 묶어서 한 번에 보여줄지 결정합니다. 예를 들어 Time Steps = 30이면, 과거 30초(혹은 30사이클) 동안의 데이터 흐름을 보고 현재의 수명을 예측합니다.
- 변환 방식: 1칸씩 옆으로 이동(Sliding)하며 데이터를 묶습니다.
 $X_1 : t_1 \sim t_{30} \text{ 데이터} \rightarrow Y_1 \text{ (예측 RUL)}$
 $X_2 : t_2 \sim t_{31} \text{ 데이터} \rightarrow Y_2 \text{ (예측 RUL)}$
- 입력 형태: (데이터 샘플 수, 30, 추출된 Feature 개수)

3. LSTM 신경망 아키텍처 설계

- 복잡한 열화 패턴을 학습하기 위한 기본적인 딥러닝 레이어 구성입니다.

- Input Layer: 준비된 3차원 슬라이딩 윈도우 데이터가 들어옵니다.
- LSTM Layer 1:
- 시간적 특징을 추출합니다. 은닉 노드(Hidden Units)는 보통 64~128개로 설정합니다.
- 다음 층도 LSTM이라면 return_sequences=True로 설정하여 시퀀스 정보를 그대로 넘겨주어야 합니다.
- Dropout Layer:
- 비율을 0.2 ~ 0.3 (20~30%)으로 설정합니다. 무작위로 뉴런을 꺼버려서 훈련 데이터에 대한 과적합(Overfitting)을 막습니다.
- LSTM Layer 2 (선택 사항):
- 데이터가 복잡할 경우 층을 하나 더 쌓아 깊은 문맥을 파악합니다. 마지막 LSTM 층이므로 return_sequences=False로 설정하여 최종 요약된 벡터만 출력합니다.
- Fully Connected Layer (Dense Layer):
- LSTM이 뽑아낸 특징들을 취합합니다. 노드 수를 32개, 16개 등으로 점차 줄여나갑니다. 활성화 함수로는 ReLU를 주로 사용합니다.
- Output Layer:
- 단 하나의 노드(Dense(1))를 가집니다.
- 연속적인 수치(수명)를 예측하는 회귀 문제이므로 활성화 함수를 사용하지 않거나(Linear) ReLU(수명이 음수가 될 수 없으므로)를 사용합니다.

○

4. 학습 파라미터 및 튜닝 포인트

- 손실 함수 (Loss Function): RUL 예측은 회귀 문제이므로 예측값과 실제값의 차이를 계산하는 MSE (평균제곱오차), RMSE, 또는 이상치에 덜 민감한 Huber Loss를 사용합니다.
- 최적화 알고리즘 (Optimizer): 학습 속도와 안정성이 뛰어난 Adam 옵티마이저를 기본적으로 사용하며, 학습률(Learning Rate)은 \$0.001\$ 정도로 시작해 미세 조정합니다.
- Early Stopping (조기 종료): 검증 세트(Validation Set)의 손실(Loss)을 모니터링하다가, 성능이 더 이상 개선되지 않고 오히려 나빠지기 시작하면 학습을 자동으로 멈추게 하여 과적합을 방지합니다.

예지보전(Predictive Maintenance, PdM) 모델의 예측 결과를 공장의 기존 MES (제조실행시스템)와 SCM(공급망관리) 모듈에 연동하여 자율적인 의사결정 체계 (Closed-loop)를 구축하는 아키텍처 방안

- 단순히 "고장이 예상됩니다"라는 알람을 띄우는 것을 넘어, 생산 계획을 자동으로 조정하고 필요한 부품을 미리 확보하는 통합 시스템을 구성하려면 다음과 같은 3계층 연동 아키텍처가 필요합니다.
- 데이터 연동 아키텍처 3계층 (3-Layer Architecture) : 이 아키텍처는 현장의 센서 데이터가 AI 모델을 거쳐 최종적으로 MES와 SCM의 실행 명령으로 변환되는 흐름을 다룹니다.

1. 미들웨어 및 통합 계층 (Integration Layer)

- AI 모델의 추론 결과(RUL 수치, 고장 모드, 이상 점수 등)를 MES와 SCM이 이해할 수 있는 표준 포맷으로 변환하고 분배하는 신경망 역할을 합니다.
- 비동기 메시지 브로커 (Kafka, MQTT): 수많은 설비에서 발생하는 예측 데이터를 실시간으로 수집하고 버퍼링합니다. MES와 SCM은 각자 필요한 토픽(Topic)만 구독(Subscribe)하여 데이터를 가져옵니다.
- API Gateway / Webhook: 긴급한 설비 고장 예측(예: "RUL 12시간 남음")이 발생하면, 미들웨어에서 MES나 CMMS(설비관리시스템)로 즉각적인 Webhook을 쏘서 강제 알람을 발생시킵니다.
- 데이터 문맥화 (Contextualization): 단순한 예측 수치에 ERP의 자산 정보, 정비 이력 등을 결합하여 "A라인 3번 모터(자산번호 1234)의 베어링 외륜 결함 징후 발견"과 같은 의미 있는 데이터로 가공합니다.


2. MES 연동 계층 (생산 실행 및 설비 관리)

- 예측된 잔여 수명(RUL)을 바탕으로 공장 현장의 작업 지시와 생산 스케줄을 동적으로 조정합니다.
- 작업 지시서(Work Order) 자동 생성: 예측 결과가 위험 임계치를 넘으면 MES 내의 CMMS 모듈이 자동으로 정비 작업 지시서를 생성하고 담당자에게 알림을 보냅니다.
- APS(고급 생산 계획) 자율 재스케줄링 (Re-routing): 특정 모터의 수명이 며칠 남지 않았다면, MES의 APS 모듈은 해당 라인에 배정되었던 긴급/대량 주문을 RUL이 넉넉한 정상 라인으로 자동 변경하여 예기치 않은 공정 중단을 방지합니다.
- 설비 부하 제어: 고장이 임박했으나 당장 수리가 어려울 경우, MES가 해당 설비의 생산 속도나 부하를 10~20% 낮추도록 지시하여 완전 정지 시점을 연장합니다.

3. SCM 연동 계층 (자재 소요 및 공급망 관리)

- 정비 지시가 내려졌을 때 필요한 부품(예비품)이 창고에 있는지 확인하고, 없으면 발주하는 과정입니다.
- 안전 재고 실시간 확인: AI가 특정 부품(예: 6205-ZZ 베어링)의 결함을 진단하면, SCM 모듈(또는 ERP)을 조회하여 현재 재고량을 파악합니다.
- 자동 발주 (Auto-Procurement): 창고에 해당 부품이 없거나 안전 재고 미달인 경우, SCM은 협력사의 리드타임(도입 소요 시간)을 계산하여 자동으로 구매 요청서(PR)를 생성합니다.
- 유지보수 일정 최적화: 부품이 공장에 도착하는 예상 날짜와 MES의 생산 계획을 종합하여, 공장 가동 피해가 가장 적은 날(예: 주말 또는 교대 시간)로 정비 일정을 자동 확정합니다.
- 통합 데이터 흐름 시나리오
- [AI 모델] 진동 센서 데이터를 분석한 1D-CNN과 LSTM 모델이 "3번 라인 모터의 내륜 베어링 파손 징후 감지. 잔여 수명(RUL) 5일 예상"이라는 결과를 도출하고 Kafka로 발행합니다.
- [SCM 시스템] 메시지를 구독한 SCM이 해당 베어링 재고를 확인합니다. 재고가 0개이므로, 리드타임이 2일인 부품 공급사 시스템에 자동 발주를 넣습니다.
- [MES 시스템] 발주된 부품이 2일 뒤 도착한다는 정보를 바탕으로, MES의 스케줄러(APS)는 3일 뒤 야간 교대 시간에 해당 설비의 유지보수 일정을 잡습니다. 동시에 그 3일 동안은 해당 모터의 부하를 줄이기 위해 생산 속도를 약간 낮추도록 제어 명령을 내립니다.

Predictive Maintenance Architecture



○